

Relazione - Versione 1: Modello statistico a caratteri

Introduzione

La Versione 1 è il primo modello funzionante del progetto Building LLM.

L'obiettivo è costruire da zero un modello linguistico semplice e interpretabile, usando esclusivamente Python standard e senza reti neurali o framework esterni.

Questa versione si concentra sul flusso fondamentale di un modello a caratteri:

```
Testo di training
↓
Copie di caratteri
↓
Conteggi delle transizioni
↓
Probabilità
↓
Campionamento
↓
Testo generato
```

La struttura è volutamente essenziale: ogni passaggio resta visibile e può essere controllato direttamente.

Obiettivo della Versione 1


Il modello deve essere in grado di:

- leggere un piccolo corpus inglese;
- costruire il vocabolario dei caratteri;
- creare esempi formati da carattere corrente e carattere successivo;
- apprendere i conteggi delle transizioni;
- convertire i conteggi in probabilità;
- generare testo campionando un carattere alla volta.

Questa versione è la base didattica del progetto.

Architettura

Il flusso completo della Versione 1 è:



Il modello usa come contesto un solo carattere. Per ogni carattere osservato, memorizza quali caratteri sono comparsi subito dopo e quante volte.

La generazione è autoregressiva: il carattere appena generato diventa il nuovo contesto per il passo successivo.

Corpus e vocabolario

Il corpus è un breve testo inglese incorporato direttamente nel notebook. Non sono necessari file esterni.

Il vocabolario è l'insieme di tutti i simboli distinti presenti nel corpus. In un modello a caratteri, lettere, spazi, punteggiatura e ritorni a capo sono token.

```
vocabulary = sorted(set(corpus))
```

```
Vocabulary size: 27
```

```
'\n ,.abcdefghijklmnopqrstuvwxyz'
```

Esempi di training

Ogni coppia di caratteri adiacenti costituisce un esempio. Il primo carattere è il contesto e il secondo è il target da prevedere.

Per il frammento model gli esempi sono:

```
m -> o
o -> d
d -> e
e -> l
```

Nel notebook gli esempi vengono costruiti accoppiando il corpus con una copia spostata di una posizione.

```
examples = list(zip(corpus, corpus[1:]))
```

Con 441 caratteri si ottengono 440 esempi, perché l'ultimo carattere non ha un carattere successivo.

Modello statistico

L'addestramento consiste nel contare le transizioni osservate. Per ogni carattere corrente viene mantenuto un contatore dei possibili caratteri successivi.

```
for current_character, next_character in zip(text, text[1:]):
    counts[current_character][next_character] += 1
```

La tabella dei conteggi è il modello appreso. Non esistono ancora pesi neurali, embedding o ottimizzazione tramite gradienti.

Probabilità

Per ottenere una distribuzione, ogni conteggio viene diviso per il totale delle transizioni osservate dallo stesso carattere corrente.

$$P(\text{next} \mid \text{current}) = \frac{\text{count}(\text{current} \rightarrow \text{next})}{\text{total counts}(\text{current})}$$

La somma delle probabilità relative allo stesso contesto è uguale a 1. Se un carattere non possiede transizioni, la funzione restituisce un dizionario vuoto.

Per il carattere m il corpus produce:

o: 4/18 a: 4/18 e: 4/18
spazio: 2/18 p: 2/18 s: 2/18

Campionamento

Il generatore non sceglie sempre lo stesso carattere. Campiona dalla distribuzione appresa: i caratteri con probabilità maggiore hanno più possibilità di essere selezionati.

```
random_generator.choices(  
    characters,  
    weights=weights,  
    k=1  
)[0]
```

Un seed locale rende il risultato riproducibile senza modificare lo stato casuale globale di Python.

Generazione del testo

A partire da un carattere iniziale, il generatore ripete quattro operazioni:

- legge il carattere corrente;
- campiona il carattere successivo;
- aggiunge il carattere all'output;
- usa il nuovo carattere come contesto successivo.

La funzione controlla che la lunghezza richiesta sia almeno 1 e che il carattere iniziale sia stato osservato durante il training.

```
generate_text(model, start_character="i", length=300, seed=42)
```

Il testo prodotto può assomigliare localmente all'inglese, ma non mantiene una coerenza a lungo termine perché il contesto contiene un solo carattere.

Test inclusi

Le asserzioni del notebook verificano:

- il numero corretto di esempi;
- la somma delle probabilità uguale a 1;
- la riproducibilità con lo stesso seed;
- la lunghezza richiesta dell'output.

L'esecuzione completa termina con il messaggio `All checks passed.`

Cosa insegna la Versione 1

L'idea principale è:

osservare -> contare -> normalizzare -> campionare -> ripetere

La Versione 1 mostra che un modello linguistico può essere descritto come una distribuzione del simbolo successivo condizionata dal contesto disponibile.

Rende inoltre concreto il ciclo autoregressivo che verrà mantenuto, con contesti e modelli più potenti, nelle versioni successive.

Limitazioni

Questa prima versione presenta limitazioni intenzionali:

- il contesto contiene un solo carattere;
- il corpus è piccolo e incorporato nel notebook;
- le transizioni mai osservate hanno probabilità zero;
- il modello non comprende parole, frasi o significato;
- la qualità del testo dipende interamente dai conteggi del corpus.

Queste limitazioni definiscono il punto di partenza del percorso.

Conclusione

La Versione 1 è il primo modello funzionante di Building LLM. Trasforma un corpus in esempi, apprende una tabella di transizioni, costruisce distribuzioni di probabilità e genera nuovo testo un carattere alla volta.

Il risultato è semplice, completamente ispezionabile e coerente con l'obiettivo di costruire un modello linguistico dalle basi.