Relazione - Versione 12: Pipeline di Training e Checkpoint

Introduzione

La Versione 12 mantiene il piccolo Transformer decoder-only e la pipeline pubblica WikiText/BPE introdotti nella Versione 11. La sorgente esterna WikiText-103 Raw v1, il tokenizer BPE addestrato solo sul training, la costruzione dei target, i due Transformer block causali, l'obiettivo di predizione del token successivo, batch size, learning rate e budget di 20 epoche vengono preservati.

Il nuovo concetto è la gestione esplicita dello stato di training e dei checkpoint. Il notebook separa lo stato più recente usato per riprendere il training dallo stato migliore selezionato tramite validation loss, quindi ricostruisce un nuovo modello finale da BEST prima di valutare lo split di test.

```
testo WikiText-103
|
tokenizer BPE addestrato sul testo di training selezionato
|
contesti di 16 token + target traslati
|
embedding token + posizione
|
Transformer block 1
|
Transformer block 2
|
logits del vocabolario a ogni posizione
|
training fino a epoca 10 -> salvataggio LAST e BEST
|
restore LAST in un nuovo modello -> ripresa 11-20
|
restore BEST in un nuovo modello finale
|
test + predizione next-token + generazione greedy + ispezione attention
```

Obiettivo della Versione 12

- preservare l'intero esperimento WikiText/BPE della Versione 11;
- tracciare solo lo stato minimo necessario alla ripresa: epoca completata, migliore epoca e migliore validation loss;
- salvare LAST a ogni epoca in modo che un run interrotto possa continuare dall'epoca successiva corretta;
- salvare BEST solo quando la validation loss migliora;
- simulare un'interruzione dopo l'epoca 10, ripristinare LAST in un nuovo modello e continuare fino all'epoca 20;
- ripristinare un altro nuovo modello da BEST prima di test, predizione, generazione e ispezione dell'attention;
- mantenere l'implementazione didattica ed esplicita senza introdurre infrastruttura di checkpoint da produzione.

Architettura

Il flusso completo della Versione 12 è:
Dataset: WikiText-103 Raw v1
|
Righe selezionate: train 10.000 / validation 1.000 / test 1.000
|
Vocabolario BPE: 2048 token
|
Sequenze usate: train 12.000 / validation 2.000 / test 2.000
|
Tensore input: (N, 16) / tensore target: (N, 16)
|
Embedding token: (2048, 8) + posizioni: (16, 8)
|
Transformer block 1: (16, 8) -> (16, 8)
|
Transformer block 2: (16, 8) -> (16, 8)
|
Logits vocabolario: (16, 2048) per esempio
|
Gradient descent mini-batch dipendente dall'epoca + validation a ogni epoca
|
LAST per la ripresa / BEST per la selezione
|
Nuovo modello ripristinato da BEST per la valutazione finale

Continuità con la Versione 11

Il notebook legge gli stessi due shard WikiText di training e i file Parquet ufficiali di validation e test usati nella Versione 11. Le righe vuote vengono rimosse prima del campionamento deterministico e i confini originali degli split restano invariati. Il vocabolario BPE viene appreso solo dal testo di training selezionato; validation e test non influenzano la costruzione del vocabolario.

Aggiunte alla pipeline di training

- TransformerBlock e DecoderOnlyLanguageModel ereditano da tf.Module soltanto per rendere le variabili esistenti tracciabili dai checkpoint; la matematica forward non cambia.
- Gli esempi di training usano shuffle_seed = SEED + epoch, così un run ripristinato continua con lo shuffle associato all'epoca successiva corretta.
- La validation loss viene calcolata a ogni epoca perché BEST deve essere aggiornato ogni volta che la validation migliora.
- Il dataset di test viene costruito prima, ma non viene valutato fino al completamento della selezione BEST.

Parametri addestrabili

Il modello continua a contenere 23 variabili TensorFlow addestrabili ed esattamente 34.496 parametri addestrabili:

Componente	Parametri
Token embeddings	2048 x 8 = 16384
Positional embeddings	16 x 8 = 128
Transformer block 1	800
Transformer block 2	800
Output weights	8 x 2048 = 16384
Totale	34496

Ogni Transformer block continua a contribuire 800 parametri:

Parte	Shape	Params
Query projection	8 x 16	128
Key projection	8 x 16	128
Value projection	8 x 16	128
Attention output	16 x 8	128
LayerNorm 1 scale + shift	8 + 8	16
Feed-forward input	8 x 16	128
Feed-forward output	16 x 8	128
LayerNorm 2 scale + shift	8 + 8	16
Per blocco		800

Stato e semantica dei checkpoint

La Versione 12 mantiene deliberatamente minimo lo stato dei checkpoint. completed_epoch registra l'ultima epoca completata; best_epoch registra l'epoca con la validation loss più bassa; best_validation_loss memorizza quel minimo. Non esiste un oggetto optimizer perché vengono preservati gli aggiornamenti manuali della Versione 11.

Stato	Contenuto	Scopo
LAST	model + completed_epoch + best metadata	ripresa
BEST	model + best epoch/loss	selezione
FINAL	fresh model restored from BEST	test + analisi

Loss, training e risultati dei checkpoint

La sparse softmax cross-entropy viene ancora calcolata su tutte le 16 posizioni target. Le loss a livello di dataset vengono pesate per token tra i mini-batch. tf.GradientTape calcola i gradienti per le stesse 23 variabili addestrabili, i gradienti sparsi degli embedding usano scatter_sub e quelli densi usano assign_sub.

Impostazione	Valore
Learning rate	1.0
Batch size	32
Seed	42
Epoca di interruzione	10
Epoche totali	20
Sequenze training	12.000 -> 375 batch
Sequenze validation	2.000 -> 63 batch
Sequenze test	2.000 -> 63 batch

Esecuzione salvata della Versione 12

Misura	Valore
Initial train loss	7.626330
Initial validation loss	7.625952
Epoch 1 train / validation	6.030380 / 5.521137
Epoch 10 train / validation	5.068344 / 5.108189
Restored completed epoch	10
Resume begins at epoch	11
Epoch 20 train / validation	5.015265 / 5.082863
BEST epoch	18
BEST validation loss	5.074273
Final BEST-restored train loss	4.986566
Final BEST-restored validation loss	5.074273
Test loss	5.105811
Uniform-vocabulary baseline	7.624619

La piccola differenza tra la validation loss dell'epoca 20 5.082863 e la loss BEST più bassa all'epoca 18 5.074273 rende concreto il nuovo concetto: LAST e BEST non identificano necessariamente lo stesso modello. LAST risponde a dove il training è arrivato e può riprendere; BEST risponde a quale modello osservato è stato selezionato dalla validation.

Ispezione delle probabilità next-token e dell'attention

Per il contesto di test non visto "Little Gidding is the fourth and final poem", le maggiori probabilità dell'ultima posizione sono virgola 0.1380 punto 0.0794 and 0.0469 in 0.0345 apostrofo 0.0256 was 0.0258 e of 0.0289 Il vero token successivo è of con probabilità 0.0289 L'attention dell'ultima posizione del Block 1 è quasi uniforme vicino a 0.0625. Il Block 2 è più selettivo, con pesi elevati tra cui G = 0.3228 f = 0.1224 the = 0.0520 e L = 0.2162 Entrambe le righe finali sommano a 1.000000 e i test completi confermano attention nulla verso il futuro.

Generazione autoregressiva

La generazione resta identica nel metodo alla Versione 11: il prompt viene codificato con lo stesso tokenizer BPE, i 16 identificatori più recenti formano il contesto e il greedy decoding sceglie ripetutamente il token successivo con probabilità più alta. L'unica differenza della Versione 12 è che la generazione usa final_model ripristinato da BEST.

Prompt salvato:

Little Gidding is the fourth and final poem

Generazione decodificata salvata:

Little Gidding is the fourth and final poem , and the Sess , and the Sess , and the Sess , and the Sess , and the Sess , and the Se

Il run aggiunge esattamente 40 token BPE. Il pattern ripetuto è coerente con il modello volutamente piccolo, il contesto di 16 token e il greedy decoding. La pre-tokenizzazione whitespace può inoltre produrre spazi prima della punteggiatura; è un effetto di formattazione del tokenizer e non un errore del Transformer.

Controlli inclusi

- la dimensione del vocabolario è esattamente 2048;
- i tensori input/target di training, validation e test hanno lunghezza 16 e le dimensioni massime previste;
- la prima sequenza target coincide con il primo input traslato di un token;
- l'output del modello ha forma (1, 16, 8), i logits (1, 16, 2048), restano due Transformer block indipendenti e il totale è esattamente 34.496 parametri;
- esistono i file dei checkpoint LAST e BEST;
- restored_epoch è esattamente 10 e completed_epoch dopo la ripresa raggiunge 20;
- selected_best_epoch coincide con l'epoca migliore selezionata dalla validation, cioè 18;
- final_model è un oggetto distinto ripristinato da BEST;
- la validation loss finale coincide con la validation loss memorizzata in BEST entro la tolleranza numerica;
- tutte le loss riportate sono finite, training/validation finali migliorano rispetto ai valori iniziali e la test loss resta sotto la baseline casuale;
- le righe dell'attention causale sommano a 1 e le posizioni future sono nulle;
- la distribuzione next-token ispezionata è finita e somma a 1;
- la generazione autoregressiva aggiunge esattamente 40 nuovi token BPE;
- il notebook termina con All checks passed.

Cosa insegna la Versione 12

La Versione 12 è il primo passaggio del progetto in cui il training diventa esplicitamente ripristinabile e la selezione del modello tramite validation viene separata dai parametri più recenti in memoria. La progressione concettuale è:
modello WikiText/BPE della Versione 11
-> epoca di training riutilizzabile
-> shuffle deterministico specifico per epoca
-> checkpoint LAST per la continuità
-> interruzione all'epoca 10
-> nuovo modello ripristinato da LAST
-> ripresa dall'epoca 11 fino alla 20
-> checkpoint BEST selezionato dalla validation loss
-> nuovo modello finale ripristinato da BEST
-> una valutazione finale sul test e analisi post-training

La differenza importante rispetto alla Versione 11 non è una nuova equazione del modello. Rappresentazione dei dati, tokenizzazione BPE e matematica del Transformer restano volutamente invariati, così l'effetto dello stato esplicito di training, della ripresa e della selezione del modello può essere isolato direttamente.

Limitazioni

- vengono usati solo subset controllati di WikiText-103;
- il modello resta volutamente minuscolo con rappresentazioni a 8 dimensioni, due Transformer block e un solo meccanismo di attention per blocco;
- la lunghezza del contesto resta fissa a 16 token BPE;
- la configurazione BPE basata su whitespace è volutamente semplice e può introdurre spazi prima della punteggiatura;
- il greedy decoding resta deterministico e può amplificare pattern ripetitivi;
- la directory runtime-v12 viene deliberatamente eliminata e ricreata all'inizio di ogni Run All, quindi la persistenza tra sessioni Kaggle separate è fuori dallo scopo didattico di questa versione;
- lo stato dei checkpoint è volutamente minimo e non include stato dell'optimizer perché il notebook continua a usare aggiornamenti manuali dei gradienti;
- non sono ancora presenti learning-rate schedule, dropout, mixed precision o infrastruttura di training su scala maggiore.

Conclusione

La Versione 12 aggiunge con successo continuità del training tramite checkpoint e selezione del modello tramite validation al language model subword su dati pubblici della Versione 11, senza modificarne l'architettura centrale. L'esecuzione salvata dimostra il comportamento completo previsto: il training si interrompe all'epoca 10, LAST ripristina un nuovo modello che riparte dall'epoca 11, il training raggiunge l'epoca 20, BEST identifica l'epoca 18 come modello con validation più bassa e un modello finale separato ripristinato da BEST produce le misure finali di training, validation e test prima di predizione, generazione e ispezione dell'attention. Il progetto dispone ora di una base pulita di stato del training su cui costruire successive funzionalità di ottimizzazione e scaling.