Relazione - Versione 13: Valutazione e Generazione Controllata

Introduzione

La Versione 13 mantiene invariati il dataset WikiText-103 Raw v1, il tokenizer BPE, il Transformer decoder-only a due blocchi, le impostazioni di ottimizzazione e la pipeline di checkpoint della Versione 12. Il nuovo concetto è la valutazione held-out accompagnata da controlli espliciti di generazione.

Il checkpoint BEST selezionato dalla validation viene ripristinato prima di misurare il test. Alla cross-entropy si aggiungono perplexity, accuracy top-1 e accuracy top-5. Temperature, top-k e top-p sono implementati direttamente dai logits dell'ultima posizione, così il decoding può essere studiato senza modificare i parametri del modello.

modello base V13 ripristinato da BEST

```
-> cross-entropy + perplexity + accuracy top-1/top-5
-> distribuzioni next-token controllate
-> generazione greedy / temperature / top-k / top-p
-> ispezione attention + test
```

Obiettivo della Versione 13

- preservare integralmente training e checkpoint della Versione 12
- valutare sul test held-out soltanto il modello selezionato dalla validation
- riportare cross-entropy, perplexity, accuracy top-1 e top-5
- implementare temperature, top-k e top-p direttamente dai logits
- confrontare le regole di decoding con lo stesso prompt, 40 nuovi token BPE e seed 42
- mantenere l implementazione esplicita e riproducibile

Architettura e continuità

```
WikiText-103 Raw v1
-> righe selezionate 10.000 / 1.000 / 1.000
-> vocabolario BPE 2.048
-> sequenze usate 12k / 2k / 2k, contesto 16
-> token + positional embeddings
-> Transformer block 1
-> Transformer block 2
-> train 1-10 -> restore LAST -> ripresa 11-20
-> restore BEST -> test held-out + decoding controllato
```

Continuità con la Versione 12

Il tokenizer continua a essere appreso soltanto dal testo WikiText di training selezionato; validation e test non influenzano il vocabolario. Restano invariati batch size 32, learning rate 1.0, budget di 20 epoche, shuffle deterministico dipendente dall'epoca e semantica minima dei checkpoint LAST/BEST.

Nuovo stadio post-training

- il test viene valutato soltanto dopo il restore di BEST
- tutte le metriche derivano dagli stessi logits next-token
- i controlli di decoding trasformano solo logits/probabilità e non aggiornano i pesi
- tutte le modalità di generazione condividono lo stesso prompt held-out e la stessa lunghezza
- il sampling stocastico usa un generatore NumPy locale con seed 42

Parametri addestrabili

Componente	Parametri
Embedding token	2048 x 8 = 16384
Embedding posizionali	16 x 8 = 128
Transformer block 1	800
Transformer block 2	800
Pesi output	8 x 2048 = 16384
Totale	34496

Ogni Transformer block continua a contribuire esattamente 800 parametri:

Parte	Shape	Parametri
Proiezione query	8 x 16	128
Proiezione key	8 x 16	128
Proiezione value	8 x 16	128
Output attention	16 x 8	128
LayerNorm 1 scala + shift	8 + 8	16
Input feed-forward	8 x 16	128
Output feed-forward	16 x 8	128
LayerNorm 2 scala + shift	8 + 8	16
Per blocco		800

Stato dei checkpoint

Stato	Contenuto	Scopo
LAST	modello + completed_epoch + metadati best	ripresa
BEST	modello + epoca/loss best	selezione
FINAL	nuovo modello ripristinato da BEST	test + analisi

La Versione 13 non aggiunge parametri addestrabili: il modello resta a 23 variabili TensorFlow addestrabili e 34.496 parametri.

Valutazione held-out

Le metriche vengono calcolate token per token sulle 2.000 sequenze di test selezionate dopo il restore di BEST. Con contesto 16, la valutazione copre 32.000 posizioni target.

Metrica	Definizione
Cross-entropy	media della log-probabilità negativa del token corretto
Perplexity	exp(cross-entropy)
Accuracy top-1	il token corretto coincide con il logit massimo
Accuracy top-5	il token corretto compare tra i cinque logits maggiori
Token valutati	2.000 x 16 = 32.000

Baseline di riferimento

La baseline uniforme resta log(2048) per la cross-entropy e 2048 per la perplexity. Queste metriche descrivono la predizione a livello di token e non misurano direttamente factuality, coerenza o utilità.

Distribuzioni controllate

Controllo	Effetto
Temperature 0.7 / 1.3	divide i logits per la temperatura prima della softmax
Top-k 20	mantiene i 20 token con probabilità maggiore e rinormalizza
Top-p 0.9	mantiene il prefisso minimo ordinato per probabilità la cui massa cumulativa raggiunge 0.9

Generazione autoregressiva controllata

La generazione parte dallo stesso prompt held-out derivato dal primo contesto di test. Ogni configurazione mantiene gli ultimi 16 token BPE e aggiunge esattamente 40 nuovi token.

Configurazione	Metodo
greedy	argmax
temperature 0.7	sampling con seed dopo la riscalatura per temperatura
top-k 20	sampling con seed sul supporto di 20 token
top-p 0.9	nucleus sampling con seed e p = 0.9

Ispezione attention

L'attenzione causale resta quella della Versione 12: ogni blocco produce una matrice 16 x 16, le righe sommano a 1 e tutte le posizioni future sono mascherate.

Controlli inclusi

- vocabolario e shape rispettano la configurazione
- il modello resta a due blocchi, 23 variabili e 34.496 parametri
- restore LAST/BEST e ripresa raggiungono epoca 20
- perplexity = exp(cross-entropy)
- accuracy top-5 >= accuracy top-1
- distribuzioni finite, non negative e normalizzate
- top-k 20 mantiene esattamente 20 probabilità non nulle
- temperature non positiva viene rifiutata
- sampling top-p con seed riproducibile
- tutte le quattro modalità aggiungono 40 token
- attention normalizzata e future-masked
- la cella finale riporta All checks passed

Cosa insegna la Versione 13

La Versione 13 separa due domande: quanto bene il modello selezionato predice token non visti e come cambia il testo generato quando cambia la regola di decoding. Il training resta volutamente invariato, quindi la nuova lezione riguarda misurazione e utilizzo del modello.

BEST base della Versione 13

```
-> cross-entropy + perplexity
-> accuracy top-1 + top-5
-> temperature / top-k / top-p
-> sampling riproducibile
```

Limiti

- solo subset controllati di WikiText-103
- modello volutamente piccolo con contesto 16
- metriche token-level non misurano direttamente factuality o utilità
- controlli di decoding semplici
- possibile generazione ripetitiva
- checkpoint persistenti tra sessioni Kaggle separate fuori ambito

Conclusione

La Versione 13 rende esplicita una valutazione held-out più interpretabile e il controllo del decoding senza cambiare modello o budget di training. Training, selezione tramite validation, misura sul test e strategia di generazione sono ora distinti in modo chiaro.

Le versioni future introdurranno nuovi componenti ed evolveranno gradualmente l'architettura.