Relazione - Versione 15: Self-Attention Causale Multi-Head Esplicita

Introduzione

La Versione 15 preserva dataset, tokenizer, training base, checkpoint, valutazione held-out, instruction tuning e generazione controllata della Versione 14. L'unico nuovo concetto è la self-attention causale multi-head esplicita.

Lo spazio di attention da 16 dimensioni viene diviso in due head indipendenti da 8 dimensioni. Le matrici Q, K, V e la proiezione di output mantengono le stesse shape, quindi il modello resta esattamente a 34.496 parametri. Il calcolo multi-head viene così isolato senza cambiare larghezza, profondità, optimizer, budget base o procedura SFT.

```
pipeline instruction-tuned della Versione 14
-> Q/K/V proiettati a 16 dimensioni
-> split in 2 head x 8 dimensioni
-> attention causale indipendente per head
-> concatenazione output a 16D
-> stessa proiezione 16 x 8
-> training + evaluation + SFT + generation preservati
```

Obiettivo della Versione 15

- introdurre due head senza aumentare i parametri
- mantenere due Transformer block e contesto 16
- verificare normalizzazione e causal mask per ogni head
- preservare checkpoint base e valutazione V13
- preservare Dolly SFT e response mask V14
- chiudere V1-V15 con una singola evoluzione architetturale

Architettura e continuità

```
BPE + contesto 16
-> rappresentazione 8D
-> Q/K/V: 8 x 16
-> reshape in 2 head x 8D
-> scaled dot-product attention causale per head
-> concatenazione a 16D
-> proiezione output 16 x 8
-> residual + LayerNorm + FFN 8 -> 16 -> 8
-> secondo blocco identico + LM head
```

Continuità con la Versione 14

Restano fisse tutte le scelte di dati e training: WikiText 10k/1k/1k, BPE 2.048, cap sequenze 12k/2k/2k, batch size 32, learning rate 1.0, 20 epoche base, Dolly 256 righe divise 192/32/32, instruction batch size 32, learning rate 0.15 e 8 epoche SFT.

Shape dell'attenzione

Elemento	Shape
Rappresentazione input	(batch, 16, 8)
Q/K/V proiettati	(batch, 16, 16)
Dopo lo split	(batch, 2, 16, 8)
Attention per head	(batch, 2, 16, 16)
Head concatenati	(batch, 16, 16)
Output attention	(batch, 16, 8)

Parametri addestrabili

Componente	Parametri
Embedding token	2048 x 8 = 16384
Embedding posizionali	16 x 8 = 128
Transformer block 1	800
Transformer block 2	800
Pesi output	8 x 2048 = 16384
Totale	34496

Ogni Transformer block continua a contribuire esattamente 800 parametri:

Parte	Shape	Parametri
Proiezione query	8 x 16	128
Proiezione key	8 x 16	128
Proiezione value	8 x 16	128
Output attention	16 x 8	128
LayerNorm 1 scala + shift	8 + 8	16
Input feed-forward	8 x 16	128
Output feed-forward	16 x 8	128
LayerNorm 2 scala + shift	8 + 8	16
Per blocco		800

Perché il numero di parametri non cambia

Le matrici Q, K e V restano 8 x 16 e la proiezione attention-output resta 16 x 8. Il multi-head cambia soltanto il modo in cui le 16 dimensioni proiettate vengono reshape e processate; non introduce nuove matrici addestrabili.

Head	Dimensione	Matrice attention
1	8	16 x 16
2	8	16 x 16

Calcolo multi-head esplicito

Dopo la proiezione Q/K/V, i tensori passano da (batch, 16, 16) a (batch, 16, 2, 8) e poi a (batch, 2, 16, 8). Ogni head calcola indipendentemente score scalati, causal mask, softmax e combinazione con V.

```
Q/K/V: (B,16,16)
-> split_heads: (B,2,16,8)
-> scores: (B,2,16,16)
-> causal softmax per head
-> output head: (B,2,16,8)
-> concatenate: (B,16,16)
-> output projection: (B,16,8)
```

Pipeline di training preservata

Il training base mantiene interruzione a epoca 10, restore LAST, ripresa fino a epoca 20 e selezione BEST. La valutazione WikiText della Versione 13 e il Dolly SFT della Versione 14 restano invariati, così il cambiamento architetturale rimane isolato.

Proprietà verificate

- NUM_HEADS = 2 e HEAD_DIM = 8
- attention di ogni blocco con shape (1, 2, 16, 16)
- ogni riga di ogni head somma a 1
- posizioni future a zero in ogni head
- totale 34.496 parametri

Valutazione, SFT e generazione preservate

La Versione 15 conserva cross-entropy, perplexity, accuracy top-1/top-5 su WikiText, restore del base BEST, split Dolly 192/32/32, SFT response-focused, selezione BEST instruction e generazione controllata base-versus-tuned.

Fase instruction

Proprietà	Valore
Formato prompt	Instruction / Context opzionale / Response
Response mask	0 sui target prompt, 1 sui target risposta
Epoche instruction	8
Learning rate instruction	0.15
Generazione instruction	greedy e top-p 0.9, 16 nuovi token BPE
Tokenizer	stesso BPE, non riaddestrato su Dolly

Controlli inclusi

- due head, dimensione head 8
- shape/normalizzazione/causal mask per head
- 23 variabili e 34.496 parametri
- resume LAST/BEST preservato
- metriche WikiText coerenti
- split Dolly disgiunti
- response mask binarie
- SFT avviato dal base BEST e parametri aggiornati
- BEST instruction ripristinato
- generazione controllata riproducibile
- la cella finale riporta All checks passed

Cosa insegna la Versione 15

La Versione 15 rende visibile la differenza tra un unico spazio di attention e più head senza confondere la lezione con un modello più grande. La stessa larghezza Q/K/V viene riorganizzata in due spazi causali normalizzati indipendentemente e poi ricombinati.

```
pipeline V14
-> Q/K/V 16D
-> split 2 x 8D
-> attention causale per head
-> concatenazione
-> stessa proiezione output
-> pipeline completa preservata
```

Limiti

- due head sono una configurazione minima
- model width 8
- contesto 16 token
- nessun dropout, Adam, learning-rate schedule o gradient clipping
- profondità e larghezza non aumentano
- instruction tuning piccolo senza preference optimization o RLHF

Conclusione

La Versione 15 chiude l'arco corrente V1-V15 con self-attention causale esplicita a due head preservando numero di parametri, training, valutazione e instruction tuning. L'ultima modifica architetturale resta isolata, direttamente ispezionabile e coerente con la filosofia una versione, un concetto, un risultato verificabile.

Le versioni future introdurranno nuovi componenti ed evolveranno gradualmente l'architettura.